Syntax natürlicher Sprachen

Vorlesung 10: Getypte Merkmalstrukturen und Unifikation

Martin Schmitt

Ludwig-Maximilians-Universität München

19 01 2021

Themen der heutigen Vorlesung

- Formale Grundlagen
 - Merkmalstrukturen
 - Subsumption
 - Unifikation
 - Bedingungen
- 2 Implementierung
 - Merkmalstrukturen
 - Unifikation

Getypte Merkmalstrukturen

Carpenter, B. (1992). The Logic of Typed Feature Structures.
Cambridge Tracts in Theoretical Computer Science. Cambridge University Press.

Typen

Definition (**Type**, \sqsubseteq)

Sei **Type** eine endliche Menge von Typen mit **Vererbungshierarchie** <u>□</u>.

Wenn für $A, B \in \mathbf{Type}$ gilt, dass $A \sqsubseteq B$, dann

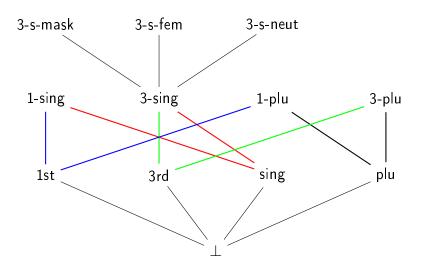
- erbt B Informationen von A.
- ist A Obertyp von B. (Alle A-Attribute sind auch B-Attribute.)
- wird B von A subsumiert.
- ist A "allgemeiner oder gleich" B.
- ist B "spezieller oder gleich" A.

Vererbung

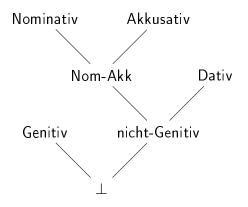
Eigenschaften von **Type**, ⊑

- wohldefinierte Unifikationsoperation
- transitiv $(\forall A, B, C \in \mathsf{Type}. \ A \sqsubseteq B \land B \sqsubseteq C \implies A \sqsubseteq C)$
- reflexiv $(\forall A \in \mathsf{Type}.\ A \sqsubseteq A)$
- antisymmetrisch ($\forall A, B \in \mathsf{Type}$. $A \sqsubseteq B \land B \sqsubseteq A \implies A = B$) (keine Vererbungsschleifen)
 - ⇒ partielle Ordnung (d. h. nicht alle Elemente von **Type** müssen miteinander vergleichbar sein)
- Existenz eines eindeutigen allgemeinsten Typs $(\exists_1 A \in \mathsf{Type}. \ \forall B \in \mathsf{Type}. \ A \sqsubseteq B)$
 - $\Rightarrow \bot$ definiert als kleinstes Element von Type bzgl. \sqsubseteq

Beispiel: Typhierarchie



Noch ein Beispiel: Typhierarchie



Vgl. z. B. die Paradigmen: der Hund, des **Hundes**, dem Hund, den Hund das Buch, des **Buches**, dem Buch, das Buch

Merkmale

Definition (Feat)

Sei Feat eine endliche Menge von Merkmalen (engl. features).

(Ohne weitere Anforderungen an Struktur oder Eigenschaften)

Beispiel

 $\textbf{Feat} = \{ \texttt{GEN}, \, \texttt{CASE}, \, \texttt{NUM}, \, \texttt{AGR}, \, \texttt{PER}, \, \texttt{MOOD}, \, \texttt{CAT}, \, \texttt{TENSE} \}$

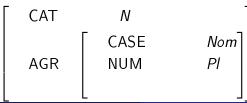
Merkmalstrukturen

Definition

Eine Merkmalstruktur über **Type** und **Feat** ist definiert als Tupel $F = (Q, \bar{q}, \theta, \delta)$ mit:

- Q : endliche Menge von Knoten (Einträge)
- ullet $ar{q} \in Q$: Wurzelknoten
- ullet $\theta:Q o {\sf Type}:$ totale Typisierungsfunktion
- ullet δ : **Feat** imes Q o Q : partielle Merkmal-Wert-Funktion

Sei \mathcal{F} die Menge aller Merkmalstrukturen.



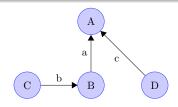
Visualisierung als Graph I

Beschrifteter Graph

Ein beschrifteter Graph ist definiert als Tupel

$$G = (V, E, I_V, I_E, L_V, L_E)$$
 mit

- V : Menge der Knoten (engl. vertices)
- $E \subseteq V \times V$: Menge der Kanten (engl. *edges*)
- $I_V: V \to L_V$: Beschriftungsfunktion für Knoten (engl. *label*)
- ullet $I_E:E o L_E:$ Beschriftungsfunktion für Kanten
- L_X : Menge von Beschriftungen für X



Visualisierung als Graph II

'Visualisierung

Der Graph zu einer Merkmalstruktur $F = (Q, \bar{q}, \theta, \delta)$ ist gegeben durch:

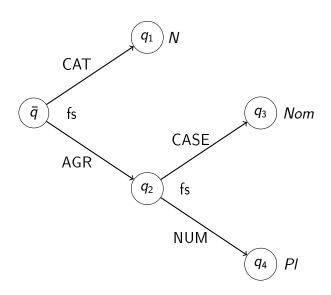
- V := Q
- $E := \{(q_1, q_2) \mid \exists f. \ \delta(f, q_1) = q_2\}$
- $L_V := \mathsf{Type}; \ l_V := \theta$
- $L_E := \mathsf{Feat}; \ l_E(q_1, q_2) := \{f \mid \delta(f, q_1) = q_2\}$

Anmerkung

Zur Vereinfachung werden einelementige Mengen ohne Mengenklammern geschrieben.

Also a statt $\{a\}$.

Beispiel: Graphdarstellung



Variablen

Variablen

- Var sei eine abzählbar unendliche Menge von Variablen.
- Häufig wird $Var = \mathbb{N}$ benutzt.
- Es gibt aber auch andere Möglichkeiten;
 z. B. im NLTK: ASCII-Identifier (?x, ?y, ...)

Definition (Zuweisungsfunktion, Valuation)

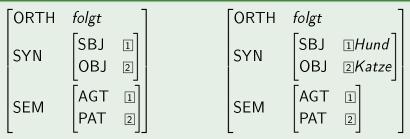
Eine Zuweisung $\alpha: \mathbf{Var} \to \mathcal{F}$ ist eine totale Funktion, die alle Variablen an Merkmalstrukturen (Knoten, Einträge) bindet.

Reentrance

Reentrance (dt. Wiedereintritt)

Durch das Aufstellen von Bedingungen (s. später) können Variablen an verschiedene Teile von Merkmalstrukturen gebunden werden. Diese müssen gleich sein.

Beispiel



Subsumption

Erweiterung auf Merkmalstrukturen

 $F = (Q, \bar{q}, \theta, \delta)$ subsumiert $F' = (Q', \bar{q}', \theta', \delta')$, genau dann wenn es eine totale Funktion $h: Q \to Q'$ gibt, sodass:

- $h(\bar{q}) = \bar{q}'$
- $\theta(q) \sqsubseteq \theta'(h(q))$ für alle $q \in Q$
- $h(\delta(f,q)) = \delta'(f,h(q))$ für alle $q \in Q$ und $f \in \mathbf{Feat}$, für die $\delta(f,q)$ definiert ist

Beispiel

$$ar{q}egin{bmatrix} q_1 \ \mathsf{CAT} & \mathsf{N} \end{bmatrix} \sqsubseteq ar{q}' egin{bmatrix} q_1' \ \mathsf{CAT} & \mathsf{N} \ q_2' \ \mathsf{GEN} & \mathsf{mask} \end{bmatrix} \qquad egin{array}{c} h(ar{q}) = ar{q}' \ h(q_1) = q_1' \end{array}$$

Unifikation I

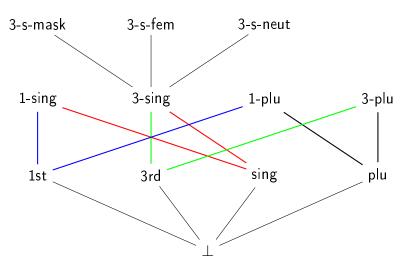
Unifikation (□) für Typen

- Das Ergebnis der Unifikation zweier Typen A, B ∈ Type ist ihre kleinste obere Schranke in Type bzgl. ⊆.
- Diese kann auch undefiniert sein (Typen unifizieren nicht).
- $A \sqcup B = C \iff A \sqsubseteq C \text{ und } B \sqsubseteq C \text{ und}$

$$\forall D \in \mathsf{Type}. \ A \sqsubseteq D \land B \sqsubseteq D \implies C \sqsubseteq D$$

(Vgl. Mengenvereinigung und Untermengenbeziehung)

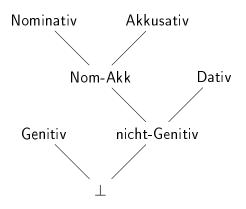
Beispiel: Typunifikation



 $1st \sqcup plu = 1-plu$

 $sing \sqcup 3-s-mask = 3-s-mask$

Noch ein Beispiel: Typunifikation



nicht-Genitiv \sqcup Nominativ = Nominativ Nom-Akk \sqcup Dativ = undefiniert

Unifikation II

Unifikation (⊔) für Merkmalstrukturen

- Algorithmus in zwei Schritten:
 - Identifiziere korrespondierende (äquivalente) Knoten
 - Unifiziere deren Typen

Formale Definition: Identifikation (Schritt 1)

Für Merkmalstrukturen $F = (Q, \bar{q}, \theta, \delta), F' = (Q', \bar{q}', \theta', \delta')$ mit $Q \cap Q' = \emptyset$ sei die Äquivalenzrelation \equiv wie folgt definiert:

- $\bar{q} \equiv \bar{q}'$
- $\delta(f,q) \equiv \delta'(f,q')$ wenn beide Seiten definiert und $q \equiv q'$

Formale Definition: Typunifikation (Schritt 2)

Die Unifikation von F und F' ist dann wie folgt definiert:

$$F \sqcup F' = ((Q \cup Q')/_{\equiv}, [\bar{q}]_{\equiv}, \theta^{\equiv}, \delta^{\equiv})$$

mit

$$heta^\equiv([q]_\equiv)=ig|\{(heta\cup heta')(q')\mid q'\equiv q\}$$

und

$$\delta^\equiv(f,[q]_\equiv) = egin{cases} [(\delta \cup \delta')(f,q)]_\equiv & \text{falls } (\delta \cup \delta')(f,q) \text{ definiert} \\ \text{undefiniert} & \text{sonst} \end{cases}$$

Notation (für \equiv Äquivalenzrelation über X)

- $\bullet [x]_{\equiv} = \{ y \in X \mid y \equiv x \}$
- $X/_{\equiv} = \{ [x]_{\equiv} \mid x \in X \}$

Beispiel: (Formale) Unifikation

$$q_{1} \begin{bmatrix} q_{2} \text{ CAT} & N \\ q_{3} \text{ AGR} & \begin{bmatrix} q_{4} \text{ NUM} & Sg \\ q_{5} \text{ CAS} & nicht-Gen \end{bmatrix} \end{bmatrix} \quad q_{6} \begin{bmatrix} q_{7} \text{ ORTH} & Hund} \\ q_{8} \text{ AGR} & \begin{bmatrix} q_{9} \text{ NUM} & Sg \\ q_{10} \text{ CAS} & Nom \end{bmatrix} \end{bmatrix}$$

$$q_6egin{bmatrix} q_7 & \mathsf{ORTH} & \mathit{Hund} \ q_8 & \mathsf{AGR} & egin{bmatrix} q_9 & \mathsf{NUM} & \mathit{Sg} \ q_{10} & \mathsf{CAS} & \mathit{Nom} \end{bmatrix}$$

- Identifikation korrespondierender Knoten
 - $q_1 \equiv q_6$ (Initialisierung)
 - Nach 1 Schritt mit δ :
 - $q_3 \equiv q_8$
 - Nach 2 Schritten mit δ :
 - $q_4 \equiv q_9$
 - $q_5 \equiv q_{10}$

Beispiel: (Formale) Unifikation

$$q_{1} \begin{bmatrix} q_{2} \text{ CAT} & N \\ q_{3} \text{ AGR} & \begin{bmatrix} q_{4} \text{ NUM} & Sg \\ q_{5} \text{ CAS} & nicht-Gen \end{bmatrix} \end{bmatrix} \quad q_{6} \begin{bmatrix} q_{7} \text{ ORTH} & Hund} \\ q_{8} \text{ AGR} & \begin{bmatrix} q_{9} \text{ NUM} & Sg \\ q_{10} \text{ CAS} & Nom \end{bmatrix} \end{bmatrix}$$

- Typunifikation
 - $Q_U = \{\{q_1, q_6\}, \{q_2\}, \{q_7\}, \{q_3, q_8\}, \{q_4, q_9\}, \{q_5, q_{10}\}\}$
 - $\bar{q}_U = \{q_1, q_6\}$
 - $\theta^{\equiv}(\{q_2\}) = N$, $\theta^{\equiv}(\{q_7\}) = Hund$, $\theta^{\equiv}(\{q_3, q_8\}) = fs$, $\theta^{\equiv}(\{q_4,q_9\}) = Sg, \; \theta^{\equiv}(\{q_5,q_{10}\}) = Nom, \; \theta^{\equiv}(\{q_1,q_6\}) = fs$
 - $\delta(\mathsf{CAT}, \{q_1, q_6\}) = \{q_2\}, \ \delta(\mathsf{ORTH}, \{q_1, q_6\}) = \{q_7\}, \ldots$

Theoretische Resultate

Lemma

Wenn $F \sqcup F'$ definiert ist, dann ist $F \sqcup F' \in \mathcal{F}$ eine Merkmalstruktur.

Theorem

 $F \sqcup F'$ ist die *kleinste obere Schranke* von F und F' in $(\mathcal{F}, \sqsubseteq)$, falls F und F' eine obere Schranke haben.

Für Beweise siehe (Carpenter, 1992).

Bedingungen 1

Pfade

- Sequenzen von Merkmalen werden Pfade genannt.
- Path = Feat* sei die Menge aller Pfade.
- Für $p \in Path$, $F \in \mathcal{F}$ sei F@p der Knoten in F, den man am Ende von Pfad p erhält.

|Beispiele

- AGR-NUM
- SYN-SBJ-AGR-NUM
- ORTH
- ε (der leere Pfad)

Bedingungen II

Definition (Beschreibung **Desc**)

Die Menge der Beschreibungen über **Type** und **Feat** sei die kleinste Menge, die folgende Bedingungen erfüllt:

- $A \in \mathbf{Desc}$, für alle $A \in \mathbf{Type}$
- $p: d \in \mathsf{Desc}$, für $p \in \mathsf{Path}, d \in \mathsf{Desc}$
- $x \in \mathbf{Desc}$, für alle $x \in \mathbf{Var}$
- $d \wedge e \in \mathsf{Desc}$, für $d, e \in \mathsf{Desc}$

Beispiel

- AGR-NUM: Sg
- SYN-SBJ: 1 ∧ SEM-AGT: 1

Bedingungen III

Erfülltheit

Die Erfülltheitsrelation \models^{α} zwischen Merkmalstrukturen und Beschreibungen ist gegeben durch:

- Für $A \in \mathsf{Type}$, $F \models^{\alpha} A \iff A \sqsubseteq \theta(\bar{q})$
- $F \models^{\alpha} p : d \iff F@p \models^{\alpha} d$
- Für $x \in Var$, $F \models^{\alpha} x \iff \alpha(x) = F$
- $F \models^{\alpha} d \land e \iff F \models^{\alpha} d \text{ und } F \models^{\alpha} e$

Erfülltheit: Beispiel

Sei F eine Merkmalstruktur.

$$F = \begin{bmatrix} \mathsf{CAT} & \mathbb{I} N \\ \mathsf{POS} & \mathbb{2} \\ \mathsf{AGR} & \begin{bmatrix} \mathsf{NUM} & Sg \\ \mathsf{CAS} & \textit{Nominativ} \end{bmatrix} \end{bmatrix}$$

$$\alpha(\boxed{1}) = \alpha(\boxed{2})$$

Welche Beschreibungen aus **Desc** erfüllt *F*?

• $F \models^{\alpha} N$?

Nein!

• $F \models^{\alpha} CAT : N$?

Ja!

• $F \models^{\alpha} AGR-CAS : nicht-Genitiv ?$

Ja!

Denn: nicht- $Genitiv \sqsubseteq Nominativ$

• $F \models^{\alpha} POS : N$?

Ja!

Beschreibungen als Merkmalstrukturen

MGSat (allgemeinster Erfüller)

Zu jeder konsistenten (widerspruchsfreien) Beschreibung $d \in \mathbf{Desc}$ gibt es eine Merkmalstruktur $MGSat(d) \in \mathcal{F}$ mit der Eigenschaft

$$\forall F \in \mathcal{F}. \ F \models d \iff MGSat(d) \sqsubseteq F$$

Konstruktion

- Für $A \in \mathsf{Type}$: MGSat(A) = [A]
- $MGSat(f_1f_2...f_n:d) = \begin{bmatrix} f_1 & f_2 & ... & f_n & MGSat(d) \end{bmatrix} \end{bmatrix}$
- ullet Wenn ${\sf Var}=\mathbb{N}, \ {\sf dann} \ {\it MGSat}(1)=igl[\mathbb{I}igr]$
- $MGSat(d \land e) = MGSat(d) \sqcup MGSat(e)$

Bedingungsprüfung per Unifikation: Beispiel

Grammatikregel mit Constraint

 $\texttt{NP[CAS=?y]} \ \to \texttt{DET[GEN=?x,CAS=?y]} \ \ \texttt{N[GEN=?x]}$

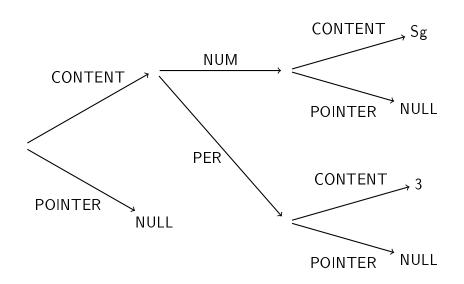
Bedingungen als Beschreibungen

- type : *NP* ∧ CAS : 2
- type : $DET \land GEN : \boxed{1} \land CAS : \boxed{2}$
- type : *N* ∧ GEN : 1

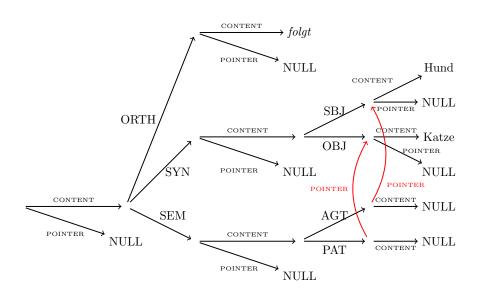
Bedingungen als Merkmalstrukturen

$$\begin{bmatrix} \mathsf{type} & \mathit{NP} \\ \mathsf{CAS} & 2 \end{bmatrix} \rightarrow \begin{bmatrix} \mathsf{type} & \mathit{DET} \\ \mathsf{GEN} & \mathbb{I} \\ \mathsf{CAS} & 2 \end{bmatrix} \begin{bmatrix} \mathsf{type} & \mathit{N} \\ \mathsf{GEN} & \mathbb{I} \end{bmatrix}$$

Merkmalstrukturen: Implementierung mit Zeigern



Reentrance (Wiedereintritt)



Unifikationsalgorithmus

```
function unify(f1-orig, f2-orig)
   f1 \leftarrow deref(f1-orig)
                                                f2 \leftarrow deref(f2-orig)
   if f1, f2 \in \mathsf{Type} then
        return unifyValues(f1, f2)

    ▷ z B per Typhierarchie

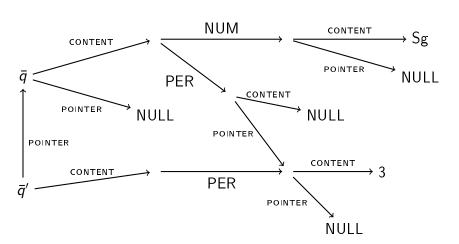
   if f1, f2 \in \mathcal{F} then
        for all feat2 \in f2 do
            feat1 \leftarrow erstelle oder finde entsprechendes Feature in f1
            if unify(feat1, feat2) = failure then
                return failure
        return f1
    . . .
```

Unifikationsalgorithmus II

```
function unify(f1-orig, f2-orig)
   if f1 \in ContPoint \land f1 content is NULL then
       f1 pointer \leftarrow f2
       return f2
   if f2 \in ContPoint \land f2 content is NULL then
       f2 pointer \leftarrow f1
       return f1
   if f1, f2 \in ContPoint then
       f2 pointer \leftarrow f1
       return unify(f1.content, f2.content)
   return failure
```

Unifikation: Implementierung mit Zeigern

$$\begin{bmatrix} \mathsf{NUM} & \mathit{Sg} \end{bmatrix} \sqcup \begin{bmatrix} \mathsf{PER} & \mathit{3} \end{bmatrix}$$



Rückblick: Heutige Themen

- Formale Grundlagen
 - Merkmalstrukturen
 - Subsumption
 - Unifikation
 - Bedingungen
- 2 Implementierung
 - Merkmalstrukturen
 - Unifikation